


Flume

Flume 概述

(1) 定义


Flume 是 Cloudera 提供的一个高可用的，高可靠的，分布式的海量日志采集、聚合和传输的系统。Flume 基于流式架构，灵活简单。

为什么选取Flume



Flume最主要的作用就是，实时读取服务器本地磁盘的数据，将数据写入到HDFS。

(2) Flume 基础架构



官网: <https://flume.apache.org/>

如图。

- Agent

Agent 是一个 JVM 进程，它以事件的形式将数据从源头送至目的。

Agent 主要有 3 个部分组成，Source、Channel、Sink。

- Source Source 是负责接收数据到 Flume Agent 的组件。Source 组件可以处理各种类型、各种格式的日志数据，包括 avro、thrift、exec、jms、spooling directory、netcat、sequencegenerator、syslog、http、legacy。
- Sink Sink 不断地轮询 Channel 中的事件且批量地移除它们，并将这些事件批量写入到存储或索引系统、或者被发送到另一个 Flume Agent。Sink 组件目的地包括 hdfs、logger、avro、thrift、ipc、file、HBase、solr、自定义。
- Channel Channel 是位于 Source 和 Sink 之间的缓冲区。因此，Channel 允许 Source 和 Sink 运作在不同的速率上。Channel 是线程安全的，可以同时处理几个 Source 的写入操作和几个 Sink 的读取操作。Flume 自带两种 Channel：Memory Channel 和 File Channel 以及 Kafka Channel。Memory Channel 是内存中的队列。Memory Channel 在不需要关心数据丢失的情景下适用。如果需要关心数据丢失，那么 Memory Channel 就不应该使用，因为程序死亡、机器宕机或者重启都会导致数据丢失。File Channel 将所有事件写到磁盘。因此在程序关闭或机器宕机的情况下不会丢失数据。
- Event 传输单元，Flume 数据传输的基本单元，以 Event 的形式将数据从源头送至目的地。Event 由 Header 和 Body 两部分组成，Header 用来存放该 event 的一些属性，为 K-V 结构，Body 用来存放该条数据，形式为字节数组。



Flume快速入门

(1) 安装部署

- 将 apache-flume-1.9.0-bin.tar.gz 上传到 linux 的/opt/software 目录下
- 解压 apache-flume-1.9.0-bin.tar.gz 到/opt/module/目录下，并改名

```
[whuc@hadoop102 ~]$ tar -zxvf /opt/software/apache-flume-1.9.0-bin.tar.gz -C /opt/module/  
[whuc@hadoop102 ~]$ mv /opt/module/apache-flume-1.9.0-bin/ /opt/module/flume-1.9.0/
```

- 将 lib 文件夹下的 guava-11.0.2.jar 删除以兼容 Hadoop 3.1.3

```
[whuc@hadoop102 flume-1.9.0]$ rm -rf lib/guava-11.0.2.jar
```

- 查看安装目录文件，conf目录下，flume-env.sh需要配置JAVA_HOME

```
[whuc@hadoop102 ~]$ cd /opt/module/flume-1.9.0/
[whuc@hadoop102 flume-1.9.0]$ cp conf/flume-env.sh.template conf/flume-env.sh
[whuc@hadoop102 flume-1.9.0]$ echo $JAVA_HOME
/opt/module/jdk1.8.0_212
[whuc@hadoop102 flume-1.9.0]$ vim conf/flume-env.sh
22 # export JAVA_HOME=/usr/lib/jvm/java-8-oracle
23 export JAVA_HOME=/opt/module/jdk1.8.0_212
```

(2) Flume 入门案例

- 需求：使用 Flume 监听一个端口，收集该端口数据，并打印到控制台。
- 需求分析：
 - 1、通过 netcat 工具向本机的 44444 端口发送数据
 - 2、Flume 监听本机的 44444 端口。通过 Flume 的 source 端读取数据。
 - 3、Flume 将获取的数据通过 sink 端写出到控制台
- 实现步骤
 - 1、安装 netcat 工具，102 安装即可，nc 是通信用的，cs 模式，自行研究

```
[whuc@hadoop102 flume-1.9.0]$ sudo yum install -y nc
```

- 2、查看 44444 端口使用情况，一般不会被占用

```
[whuc@hadoop102 flume-1.9.0]$ sudo ss -tunlp | grep 44444
[whuc@hadoop102 flume-1.9.0]$ sudo netstat -tunlp | grep 44444
```

- 3、创建 Flume Agent 配置文件 flume-netcat-logger.conf

在 flume 目录下创建 job 文件夹并进入 job 文件夹。

```
[whuc@hadoop102 flume-1.9.0]$ mkdir job
[whuc@hadoop102 flume-1.9.0]$ ll -d job
drwxrwxr-x 2 whuc whuc 6 8月  3 14:03 job
[whuc@hadoop102 flume-1.9.0]$ vim job/flume-netcat-logger.conf
```

```
# Name the components on this agent
a1.sources = r1
a1.sinks = k1
a1.channels = c1

# Describe/configure the source
a1.sources.r1.type = netcat
a1.sources.r1.bind = hadoop102
a1.sources.r1.port = 44444

# Describe the sink
a1.sinks.k1.type = logger

# Use a channel which buffers events in memory
```

```

a1.channels.c1.type = memory
a1.channels.c1.capacity = 1000
a1.channels.c1.transactionCapacity = 100

# Bind the source and sink to the channel
a1.sources.r1.channels = c1
a1.sinks.k1.channel = c1

```

从官方手册中复制，简单读一读，了解其含义

```

# Name the components on this agent
a1.sources = r1      r1:表示a1的Source的名称
a1.sinks = k1        k1:表示a1的Sink的名称
a1.channels = c1     c1:表示a1的Channel的名称

# Describe/configure the source
a1.sources.r1.type = netcat      表示a1的输入源类型为netcat端口类型
a1.sources.r1.bind = localhost  表示a1的监听的主机
a1.sources.r1.port = 44444      表示a1的监听的端口号

# Describe the sink
a1.sinks.k1.type = logger       表示a1的输出目的地是控制台logger类型

# Use a channel which buffers events in memory
a1.channels.c1.type = memory    表示a1的channel类型是memory内存型
a1.channels.c1.capacity = 1000  表示a1的channel总容量1000个event
a1.channels.c1.transactionCapacity = 100  表示a1的channel传输时收集到了100条event以后再去提交事务

# Bind the source and sink to the channel
a1.sources.r1.channels = c1     表示将r1和c1连接起来
a1.sinks.k1.channel = c1       表示将k1和c1连接起来

```

4、先开启 flume 监听端口

```

[whuc@hadoop102 flume-1.9.0]$ bin/flume-ng agent -c conf/ -f job/flume-netcat-logger.conf -n a1 -Dflume.root.logger=INFO,console

```

参数说明：（我只用了-） --conf/-c：表示配置文件存储在 conf/目录 --name/-n：表示给 agent 起名为 a1 --conf-file/-f：flume 本次启动读取的配置文件是在 job 文件夹下的 flume-telnet.conf文件。 -Dflume.root.logger=INFO,console：-D 表示 flume 运行时动态修改 flume.root.logger参数属性值，并将控制台日志打印级别设置为 INFO 级别。日志级别包括:log、info、warn、error。

5、使用 netcat 工具向本机的 44444 端口发送内容

新建终端

```

[whuc@hadoop102 ~]$ nc hadoop102 44444

```

6、查看source--channel--sink的过程

```

[whuc@hadoop102 ~]$ nc localhost 44444
123
OK
456
OK

```


```

2021-08-03 14:43:00,835 (lifecycleSupervisor-1-4) [INFO - org.apache.flume.source.NetcatSource.start(NetcatSource.java:169)] Created serverSocket:sun.nio.ch.ServerSocketChannelImpl[/127.0.0.1:44444]
2021-08-03 14:46:11,779 (SinkRunner-PollingRunner-DefaultSinkProcessor) [INFO - org.apache.flume.sink.LoggerSink.process(LoggerSink.java:95)] Event: { headers:{} body: 31 32 33 123 }
2021-08-03 14:46:15,912 (SinkRunner-PollingRunner-DefaultSinkProcessor) [INFO - org.apache.flume.sink.LoggerSink.process(LoggerSink.java:95)] Event: { headers:{} body: 34 35 36 456 }

```

- 第二个案例：实时监控单个追加文件

案例需求：实时监控 httpd 日志，并上传到 HDFS 中



实现步骤

1、Flume 要想将数据输出到 HDFS，须持有 Hadoop 相关 jar 包

```

commons-configuration-1.6.jar、
commons-io-2.4.jar、
htrace-core-3.1.0-incubating.jar

```

上传到 /opt/module/flume-1.9.0/lib 目录下

2、创建 flume-file-hdfs.conf 文件

要想读取 Linux 系统中的文件，就得按照 Linux 命令的规则执行命令。由于 Httpd 日志在 Linux 系统中所以读取文件的类型选择：exec 即 execute 执行的意思。表示执行 Linux 命令来读取文件。

```
[whuc@hadoop102 flume-1.9.0]$ vim job/file-flume-hdfs.conf
```

```

a2.sources = r2
a2.sinks = k2
a2.channels = c2

# Describe/configure the source
a2.sources.r2.type = exec
# -f 返回后10行 -F 返回后10行，会重新打开文件 日志文件通常会自动rotate
a2.sources.r2.command = sudo tail -F /var/log/httpd/access_log

# Describe the sink
a2.sinks.k2.type = hdfs
a2.sinks.k2.hdfs.path = hdfs://hadoop102:8020/flume/%Y%m%d/%H

#上传文件的前缀

```

```

a2.sinks.k2.hdfs.filePrefix = logs-
#是否按照时间滚动文件夹
a2.sinks.k2.hdfs.round = true
#多少时间单位创建一个新的文件夹
a2.sinks.k2.hdfs.roundValue = 1
#重新定义时间单位
a2.sinks.k2.hdfs.roundUnit = hour
#是否使用本地时间戳
a2.sinks.k2.hdfs.useLocalTimeStamp = true
#积攒多少个 Event 才 flush 到 HDFS 一次
a2.sinks.k2.hdfs.batchSize = 100
#设置文件类型，可支持压缩
a2.sinks.k2.hdfs.fileType = DataStream
#多久生成一个新的文件 为了测试 30秒一个新文件
a2.sinks.k2.hdfs.rollInterval = 30
#设置每个文件的滚动大小 比一个block的大小略小
a2.sinks.k2.hdfs.rollSize = 134217700
#文件的滚动与 Event 数量无关
a2.sinks.k2.hdfs.rollCount = 0

# Use a channel which buffers events in memory
a2.channels.c2.type = memory
a2.channels.c2.capacity = 1000
a2.channels.c2.transactionCapacity = 100

# Bind the source and sink to the channel
a2.sources.r2.channels = c2
a2.sinks.k2.channel = c2

```

3、安装httpd、并启动，查看日志 (sudo)

4、开启hadoop集群、开启flume

[whuc@hadoop102 flume-1.9.0]\$ bin/flume-ng agent -c conf/ -f job/file-flume-hdfs.conf -n a2

```

[whuc@hadoop102 flume-1.9.0]$ bin/flume-ng agent -c conf/ -f job/file-flume-hdfs.conf -n
a2
Info: Sourcing environment configuration script /opt/module/flume-1.9.0/conf/flume-
env.sh
Info: Including Hadoop libraries found via (/opt/module/hadoop-3.1.3/bin/hadoop) for
HDFS access
Info: Including Hive libraries found via (/opt/module/hive) for Hive access

```

5、查看hdfs上产生的文件

Browse Directory

/flume/20210804/10

Go!

Show

25

 entries

Search:

☐		Permission		Owner		Group		Size		Last Modified		Replication		Block Size		Name	
☐		-rw-r--r--		whuc		supergroup		2.38 KB		Aug 04 10:54		3		128 MB		logs-.1628045637092	
☐		-rw-r--r--		whuc		supergroup		126.07 KB		Aug 04 10:55		3		128 MB		logs-.1628045672404	
☐		-rw-r--r--		whuc		supergroup		151.29 KB		Aug 04 10:55		3		128 MB		logs-.1628045702652	
☐		-rw-r--r--		whuc		supergroup		151.29 KB		Aug 04 10:56		3		128 MB		logs-.1628045732845	
☐		-rw-r--r--		whuc		supergroup		0 B		Aug 04 10:56		3		128 MB		logs-.1628045763035.tmp	

Showing 1 to 5 of 5 entries

Previous

1

Next

File information - logs-.1628045702652



[Download](#)

[Head the file \(first 32K\)](#)

[Tail the file \(last 32K\)](#)

Block information --

Block 0 ▾

Block ID: 1073741997

Block Pool ID: BP-54734925-192.168.3.102-1627110385953

Generation Stamp: 1174

Size: 154920

Availability:

- hadoop102
- hadoop103
- hadoop104

File contents

```
192.168.3.1 - - [04/Aug/2021:10:54:32 +0800] "GET / HTTP/1.1" 403 4897 "-"
"Mozilla/5.0 (Windows NT 10.0; Win64; x64) AppleWebKit/537.36 (KHTML, like Gecko)
Chrome/92.0.4515.107 Safari/537.36"
192.168.3.1 - - [04/Aug/2021:10:54:32 +0800] "GET
/noindex/css/fonts/Bold/OpenSans-Bold.woff HTTP/1.1" 404 239
"http://hadoop102/noindex/css/open-sans.css" "Mozilla/5.0 (Windows NT 10.0;
Win64; x64) AppleWebKit/537.36 (KHTML, like Gecko) Chrome/92.0.4515.107
Safari/537.36"
```

Close

flume收集web服务器产生的日志到hdfs上的过程，很清楚。可以直接hive或者mapreduce处理。

- 3
-